

Anton_Recasens_Marc_Informe_PAC1_MO-157

Marc Anton

2025-03-31

Index

Resum	1
Objectius	1
Mètodes	1
Resultats	3
Pre-processat de les dades	3
Reducció de les dimensions	4
Cerca de patrons	5
Discussió	7
Conclusions	7
Referències	7

Resum

Objectius

Els objectius de la primera prova d'avaluació continua és planificar i executar una versió simplificada del procés d'anàlisi de dades òmiques, alhora que practicar algunes de les eines i mètodes que s'han treballat durant el primer repete.

De manera més concreta, l'objectiu ha estat generar un objecte SummarizedExperiment de Bioconductor, explorar-ne les seves possibilitats a l'hora de tractar les dades i seguir els 3 passos bàsics del procés d'anàlisi de dades òmiques que són:

1. Una anàlisi exploratòria.
2. Una reducció de variables.
3. Una cerca de patrons o classes.

Mètodes

Per afrontar els objectius proposats, s'han utilitzat els fitxers dels exemples de mostra, que es poden veure clicant **aquí**.

Aquest exemple conté les dades de l'anàlisi d'un paquet important de metabolits després de practicar dos tipus de cirurgia en pacients amb obstrucció morbida. Les dades estan estructurades en dos arxius: 1) DataInfo_S013 que conté la descripció de tots els camps que porta 2) DataValues_S013 on hi ha els valors de 694 variables

corresponents a 39 mostres. Aquests dos fitxers, s'han incorporat un objecte SummarizedExperiment de Bioconductor. SummarizedExperiment permet desar els resultats d'un experiment tant pel que fa a les metadades de l'experiment en sí com dels casos d'estudi, junt amb les dades obtingudes per les variables obtingudes. És un objecte molt similar a ExpressionSet, però se'n diferencia de manera principal perquè pot contenir més d'un conjunt de dades sobre els mateixos casos, de manera que es poden obtenir diversos experiments fets amb els mateixos subjectes d'estudi. Com en ExpressionSet, l'empaquetament que porta permet tractar les dades de manera molt còmoda al tenir en un mateix objecte i clarament referenciat i indexat les metadades i les dades, de manera que si s'elimina o s'afegeix un cas, es tracta tot de manera conjunta.

En el nostre cas, hem generat el SummarizedExperiment considerant que el paquet inicial de dades contenia unes primeres 9 variables relatives al subjecte d'estudi (o pacient) que són: 1. Un codi de pacient 2. La cirurgia a la que va ser sotmès el pacient 3. L'edat i el gènere 4. Un grup de tractament 5. 4 tractaments que venen amb 0 i 1 A continuació hi ha 686 variables de metabolits analitzats en els diferents pacients.

Per tant, el SummarizedExperiment ha tingut en compte això i s'ha generat de la següent manera:

```
# Primer carreguem la llibreria per poder tractar el SummarizedExperiment
library(SummarizedExperiment)

# A continuació carreguem les dades
DataInfo_S013 <- read.csv("DataInfo_S013.csv", sep = ",")
DataValues_S013 <- read.csv("DataValues_S013.csv", sep = ",")

# Després generem les dades de pacients i de metabolits i la llista de rownames que volem tal i com hem
pacients <- DataValues_S013[,2:10]
metabolits <- DataValues_S013[,11:696]
colNames <- DataInfo_S013[10:695,]
# Ara ja podem carregar el SummarizedExperiment
seMA <- SummarizedExperiment(assays = list(counts = as.matrix(metabolits)),
                             colData = colNames,
                             rowData = patients)
seMA
```

```
## class: SummarizedExperiment
## dim: 39 686
## metadata(0):
## assays(1): counts
## rownames: NULL
## rowData names(9): SUBJECTS SURGERY ... MEDINF_TO MEDHTA_TO
## colnames(686): GLU_TO INS_TO ... SM.C24.0_T5 SM.C24.1_T5
## colData names(4): X VarName varTpe Description
```

Ara bé, aquest primer SummarizedExperiment contenia un alt nombre de valors no obtinguts (NAs) i, fins i tot, una columna amb tots els valors desconeguts. A més, el rang dels valors és molt variable, el que dificulta l'anàlisi posterior. Per tant, s'ha procedit a:

1. Eliminar la columna que contenia només NAs
2. Imputar els valors dels NAs de la resta de columnes
3. Normalitzar les dades

Després d'una anàlisi prèvia de les dades, s'ha optat per utilitzar les funcions del paquet POMA tant per la imputació com per la normalització. Per a la imputació, s'ha fet servir la funció *PomaImpute* i s'ha utilitzat el mètode de veïns propers (*knn*) que es pot considerar la millor aproximació. Per a la normalització s'ha utilitzat la funció *PomaNormalize()* amb un mètode d'escalat *auto_scaling* que és el que ha proporcionat una major normalització gràfica de les dades. S'han rebutjat els logaritmes perquè amb les dades que tenim ens generen NAs, el *mix_max* perquè genera molta variabilitat en les dades en el nostre cas i el *box_cox* perquè

no ha funcionat amb la matriu que tenim.

En resum, el pre-processat ha estat:

```
# Carreguem les llibreries
library(POMA)
library(ggtext)
library(magrittr)

# Eliminem la columna amb només NAs
seMAclean <- seMA[, -248]

# Imputem els NAs en les columnes restants
seMAimputed <- seMAclean %>%
  PomaImpute(method = "knn", zeros_as_na = FALSE, remove_na = FALSE, cutoff = 20)

# Normalitzem les dades i grafiquem el resultat de la normalització
seMANormalized <- seMAimputed %>%
  PomaNorm(method = "auto_scaling")
```

Un cop pre-processades les dades s'han realitzat les següents anàlisi:

1. Una reducció de dimensions mitjançant un anàlisi de components principals
2. Una cerca de patrons amb dos mapes de calor procedents de: 1) la matriu de correlacions i 2) un anàlisi de distàncies.



Resultats

Els resultats es mostren de manera separada pels 3 passos que hem realitzat:

Pre-processat de les dades

El resultat del pre-processat de les dades es pot apreciar tant en un gràfic de les funcions de densitat de les variables on s'aprecia que, tot i que hi ha alguna variable amb cues molt llargues, en general, totes es comporten amb distribucions força aproximades a la normal.

```
PomaDensity(seMANormalized, x = "features")
```



Reducció de les dimensions

Tal i com ja s'ha comentat, la reducció de les dimensions s'ha fet amb una anàlisi de components principals. El resultat complet de la PCA és molt extens degut a la grandaria de la matriu que s'ha utilitzat pel que, ensenyem aquí el resultat corresponent a les 5 primeres components que explica bastant be el que es pot deduir en base a les dades disponibles:

```
PCaseMA <- prcomp(assay(seMANormalized), scale. = TRUE, rank. = 5)
summary(PCaseMA)
```

```
## Importance of first k=5 (out of 39) components:
##               PC1      PC2      PC3      PC4      PC5
## Standard deviation  18.9326  7.37793  5.80678  5.36651  5.21288
## Proportion of Variance  0.5233  0.07947  0.04922  0.04204  0.03967
## Cumulative Proportion  0.5233  0.60274  0.65196  0.69401  0.73368
```

Es pot apreciar en aquest cas que l'anàlisi no és molt concloent, ja que per a explicar un un 70% de la variabilitat de les nostres dades ens calen com a mínim 5 components. Si volguéssim arribar a un 85% ens caldrien 12 components i a un 95%, ens en caldrien 17.


Pel que fa als coeficients del model de cada component, com es pot apreciar en els resultats de l'execució completa de l'exercici (Anton_Recasens_Marc_PAC1.Rmd) no hi ha cap variable que destaquí de manera particular.

D'altra bandam, el que si ens mostra la PCA és que els dos tipus de cirurgia que es van aplicar sobre els pacients es separen en el que fa a la resposta dels metabolits. Això s'aprecia be en el gràfic de les 3 primeres components.

```

cirugia <- as.factor(rowData(seMA)$SURGERY)
cirugian <- as.numeric(cirugia)
gr3Ddata <- as.data.frame(PCaseMA$x)
gr3Ddata$cirugia <- cirugian
library(scatterplot3d)
# scatterplot3d(PCaseMA$x[,1], PCaseMA$x[,2], PCaseMA$x[,3],
scatterplot3d(gr3Ddata[,1], gr3Ddata[,2], gr3Ddata[,3],
              xlab="PC1", ylab="PC2", zlab="PC3",
              color = ifelse(gr3Ddata$cirugia == "1", "green", "orange"),
              pch = ifelse(gr3Ddata$cirugia == "1", 3, 21))
legend("topright",
      pch=c(3,21),
      col=c("green","orange"),
      cex=0.8,
      legend=c("bypass","tubular"))

```




Cerca de patrons

Pel que fa a l'anàlisi de cerca de patrons, el mapa de calor de la matriu de correlacions apunta a una baixa correlació general entre les variables, tot i que algunes semblen agrupar-se de manera clara com es pot veure a l'extrem inferior esquerra i al superior dret. Aquesta correlació es confirma amb els dendrogrames que apunten a dos grans grups de variables.

```


cor_matrix <- cor(na.omit(assay(seMANormalized)))
heatmap(cor_matrix)

```



Finalment, l'anàlisi de distàncies ens mostra, novament algunes mostres que es distancien força de la resta i fins a 3 grups de variables que podrien respondre a patrons dins de proximitat pel que fa a la seva resposta conjunta al procés estudiat

```
dist_matrix <- t(assay(seMANormalized))
heatmap(dist_matrix, col=heat.colors(16))
```



Discussió

Caldria veure l'article original per si podem treure alguna conclusió. Apuntarem les limitacions que ens hem trobat en cada fase (pre-proces, PCA i heatmaps)

Conclusions

Que bo que és bioconductor i com facilita SummarizedExperiment el tractament de les dades

Referències

El present informe presenta un resum de tot el procés d'anàlisi en el qual s'han eliminat totes les execucions de R que allarguen en excès la sortida en pdf. El procés original degudament documentat es pot consultar al següent repositori github [repositori github](#), cliqueu **aquí** on a més del procés es troba un arxiu en html i en pdf de la solució de la PAC, així com tots els fitxers addicionals, incloent el .rda amb el SummarizedExperiment